

· 综述 ·

人工智能在先天性心脏病学中的应用



谢稳^{1,2}, 姚泽阳^{1,2}, 邱海龙², 徐小维², 庄建^{1,2}

1. 华南理工大学附属广东省人民医院 心外科(广州 510100)

2. 广东省华南结构性心脏病重点实验室 广东省心血管病研究所 广东省人民医院 广东省医学科学院 心外科(广州 510100)

【摘要】 人工智能属于计算机科学领域, 在过去的几十年里, 人工智能在医学领域展现了广泛的应用前景。但直到最近几年, 随着计算机技术的进步, 医生和计算机专家才真正开始发现其应用于临床的潜力, 尤其是在先天性心脏病领域。当前, 人工智能已成功应用于先天性心脏病的预测、智能诊断、医学图像分割和识别以及临床决策支持等领域。本文综述了人工智能在先天性心脏病学中的应用。

【关键词】 人工智能; 先天性心脏病; 机器学习; 深度学习; 神经网络

Artificial intelligence in congenital cardiology

XIE Wen^{1,2}, YAO Zeyang^{1,2}, QIU Hailong², XU Xiaowei², ZHUANG Jian^{1,2}

1. Department of Cardiac Surgery, Guangdong Provincial People's Hospital, South China University of Technology, Guangzhou, 510100, P.R. China

2. Department of Cardiac Surgery, Guangdong Provincial Key Laboratory of South China Structural Heart Disease, Guangdong Provincial Cardiovascular Institute, Guangdong Provincial People's Hospital, Guangdong Academy of Medical Sciences, Guangzhou, 510100, P.R. China

Corresponding author: ZHUANG Jian, Email: Zhuangjian5413@tom.com

【Abstract】 Artificial intelligence belongs to the field of computer science. In the past few decades, artificial intelligence has shown broad application prospects in the medical field. With the development of computer technology in recent years, doctors and computer scientists have just begun to discover its potential for clinical application, especially in the field of congenital heart disease. Artificial intelligence now has been successfully applied to the prediction, intelligent diagnosis, medical image segmentation and recognition, clinical decision support of congenital heart disease. This article reviews the application of artificial intelligence in congenital cardiology.

【Key words】 Artificial intelligence; congenital heart disease; machine learning; deep learning; neural network

先天性心脏病 (congenital heart disease, CHD) 是指出生时即存在的心脏结构性缺损, 是最常见的先天性心脏畸形疾病, 占所有先天性畸形疾病的三分之一。文献^[1] 报道每 1 000 名活产婴儿中有 4.1~12.9 例 CHD 患儿。在一项研究中, van der Linde 等^[2] 使用固定效应模型分析了近 100 年 CHD 的发病趋势, 发现随着时间的推移 CHD 发病率越来越高, 由 1930 年的 1/1 000 例活产婴儿到近年来的 9/1 000 例, 并且不同地区的人群发病率不同。国内报道发病率由 1996 年的 6.15/10 000 上升至 2000 年的

11.40/10 000, 南方发病率明显高于北方, 且与孕产妇保健系统和产前诊断水平密切相关^[3]。研究^[4-5] 显示每 1 000 名活产婴儿中 6~19 例可能有中度到重度先天性心脏缺陷, 如果包括出生时出现的微小肌肉性室间隔缺损 (ventricular septal defect, VSD) 和其他小病变, 所有类型的 CHD 发病率都将增加至 75/1 000^[6]。

随着人们对心血管系统疾病的认识逐渐加深, 外科技术和介入手段的快速发展, CHD 患者生存率快速上升, 甚至可存活至成年。过去几十年中成人先天性心脏病患者 (adult congenital heart disease/defect, ACHD) 数量稳步上升, 到 2010 年, ACHD 占患有严重 CHD 患者的 60%, 占患有其他类型 CHD 患者的 66%^[7], 且长期生存率较低^[8-9]。CHD 的

DOI: 10.7507/1007-4848.201911085

基金项目: 国家重点研发计划 (2018YFC1002600); 广东省科技计划项目 (2017A070701013; 2017B090904034; 2017B030314109; 2019B020230003); 广东省登峰计划项目 (DFJH201802)

通信作者: 庄建, Email: Zhuangjian5413@tom.com



治疗方式主要为外科手术和导管介入手术, 复杂CHD患者以外科治疗为主。心脏外科的手术治疗费用昂贵, 治疗周期长, 需要面临高死亡率和再次手术的风险^[10], 许多家庭都难以承担。据Apfeld等^[11]关于先天性缺陷患儿住院期间费用的研究显示, 与其他重症患儿相比, 需要外科治疗的先天性畸形疾病在美国医疗保健系统中成本过高。Russo等^[12]也指出2004年美国先天性缺陷住院费用可高达26亿美元, 其中剖宫产和CHD相关的住院费用约占14亿美元。同样国内也有报道, 每新发CHD病例生命周期的经济负担平均是9.7万元, 2003年全国新发病例的生命周期总经济负担可达28.88亿元^[13-14]。先天性心脏畸形病种类型多且变异度大, 其直接或间接产生的社会和家庭经济负担以及政府对于公共卫生健康管理所面临的一系列应对措施等问题, 对CHD医疗健康领域的长远发展来说是一个巨大的挑战。

与此同时, 人工智能(*artificial intelligence*, AI)技术得到了迅猛发展。一方面, 在摩尔定律^[15]理论支持下, 计算机性能不断突破, 基于高性能计算和云运算的强大能力, 尤其是图形处理单元(*graphic processing units*, GPU)的不断升级使得许多理念和算法成功实行^[16], 这对机器学习应用于大量相关领域有重要推动作用。另一方面, AI作为多领域交叉学科的研究方向, 在图像识别、语音分析、自动驾驶、药物合成等领域已经展现了超越人类的潜能, 将极大提升上述领域的自动化和智能化水平。

AI技术的发展为心血管系统疾病诊疗的高效自动化和经济节约化提供了一个可行的方案。一方面, AI通过使用计算机的算法优化流程和决策的能力已成功被应用于智能诊疗、医学影像分析、电子健康病历的大数据管理、精准医疗、分子生物学及新药研发等方向, 极大地改善了医疗环境。另一方面, AI在心血管疾病的诊治上已经展现了一定的潜力: 它可以通过使用高效的算法从大量成像数据中检测和“学习”特征, 帮助医师减少诊断和治疗相关错误并促进个性化医疗, 从而达到指导临床实践的目的。此外, AI可以用于识别疾病特有的模式并关联新的特征, 以获得具有创新性的科学见解。

本文综述了AI技术在心血管领域的相关应用, 并进行了具体的分类分析。同时对文献中相关的AI技术进行了介绍。本文旨在通过对AI技术的介绍和相关工作的总结分析推动AI在心血管领域应用中的进一步发展与完善。

1 人工智能

AI是计算机科学的一个分支, 旨在模拟人类的思维过程、学习能力和知识储备。AI还诞生出一些子学科, 包括机器学习(*machine learning*, ML)/人工神经网络(*artificial neural network*, ANN)、计算机视觉(*computer vision*, CV)、自然语言处理(*natural language processing*, NLP)、深度学习(*deep learning*, DL)、专家系统(*expert system*)/临床决策支持系统(*clinical decision support system*, CDSS)以及机器人学(*robotics*)等领域(图1)。

1.1 机器学习/人工神经网络

ML是指计算机执行预定义任务并从经验和输入中学习更多观察的过程^[17-18]。1943年, Warren和Walter基于神经细胞生物过程的原理提出了神经元的M-P模型^[19], 这是历史上首次提出的神经元数学模型, 开创了ANN的研究时代。之后的研究陆续提出了有关神经网络的Hebb学习规则^[20], 以M-P模型为基础的感知器(*perceptron*)^[21]以及自适应线性神经网络(*adaptive linear neuron*)^[22]等算法, 促进了ANN的研究应用和发展。ANN的设计类似于人的大脑, 由许多层相互连接的数据处理器组成, 这些处理器具有不同的权重, 通过学习算法(例如反向传播)训练网络的权重, 呈现成对的输入信号和期望的输出决策, 模仿大脑依赖外部感觉刺激来学习实现特定任务的条件以反映决定目标输出或触发动作的相互依赖关系^[23-24]。ANN的发展和演变使我们更接近于复制机器在人类中学习的方式, 更多的是要考虑到有多种算法可以用来满足不同目标的需要。单个模型不能应用于全局, 因为这样会导致次等结果, 同时可能无法满足主要用户的需求。所有机器学习算法的基础都建立在预测建模的三个步骤上: 数据准备、数据拟合的模型选择和模型验证。ANN可以学习的数据越多, 它就能更好地通过算法结构微调整扩大其预测能力。

1.2 深度学习

DL是ML的一个分支, 它能够使计算机通过层次概念来学习经验和理解世界^[25]。基于ANN的知识结构和学科应用, DL将AI技术向前推进了一步。DL与传统ML的不同之处在于如何从原始数据中学习到模型表示, 即表示学习(*representation learning*), 使用ML来发掘表示本身, 而不仅仅把表示映射到输出^[26]。与ANN相比, 它们的主要区别在于深度神经网络具有多隐藏层的维度、多隐藏层的连接以及学习有意义的抽象输入的能力。DL

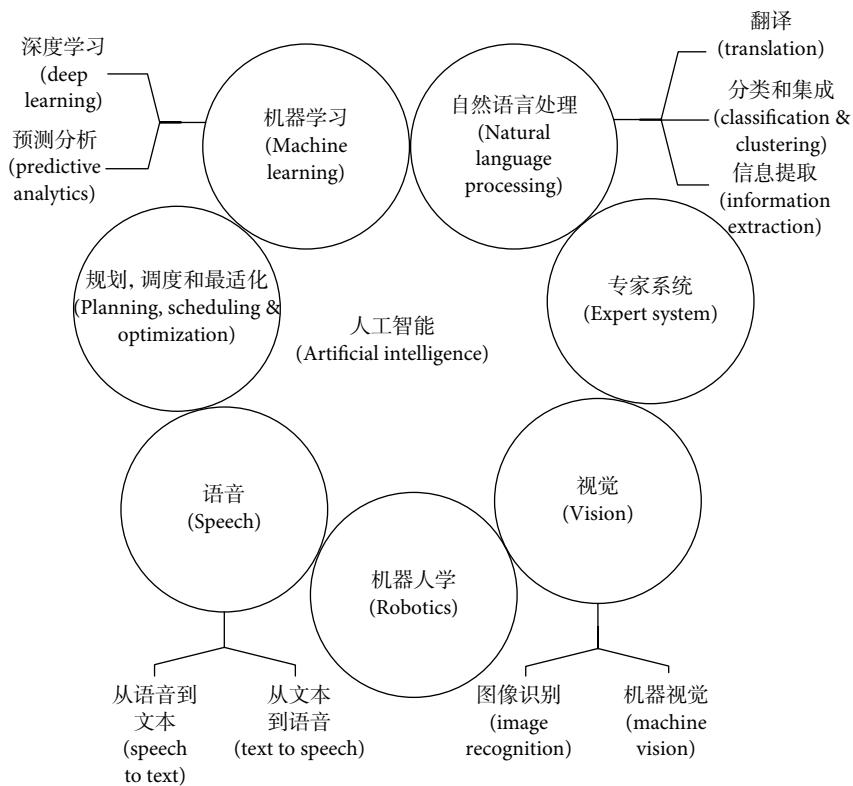


图 1 人工智能的各学科领域介绍

的神经网络具有多个隐藏层，一个层由一组节点组成，有时称为“特征”或“单元”，这些节点通过边缘连接到更早和更深的层^[27]（图 2）。此种算法可以自动设计具有适合多种任务的特性，并为一个或多个特定任务自定义这些功能。事实上，DL 被证明擅长在高维数据中发现复杂的结构，能够从大量数据，特别是无监督数据中提取高级、复杂的抽象和数据表示^[29]，并在图像领域^[30-32]、语音识别^[33]、自然语言理解^[34]和翻译^[35]等方面拥有显著的目标检测性能。DL 在医疗保健方面也取得了较大进展，包括眼底视网膜检查^[36-37]、临床影像图像重建与分割^[30, 38]、病理图像检测与识别^[39-40]、基因组学^[41-42]以及电子健康病历（electronic health record, EHR）管理^[43-44]等相关专业领域。

1.3 专家系统/临床决策支持系统

专家系统是为解决某一特定领域的复杂问题而开发的计算机应用程序，具有最高水平的人类智慧和专业知识。在神经网络发明之前，人们使用专家系统旨在利用知识系统的推理能力来解决复杂的问题。早期开发创建的专家系统被应用于医学和生物学诊断的计算机辅助系统^[45]，但由于其使用传统方法（概率论^[46]或流程图^[47]）而存在很大的局限性。1965 年斯坦福大学利用列表处理（list processing, LISP）语言开发并推出了第一个专家系

统 DENDRAL^[48]，旨在确定化合物分子结构。后来又创建了基于反向链接原理的 MYCIN 专家系统^[49]，该系统可以识别引起严重感染的各种细菌，推荐可使用的抗生素并根据患者体重调整合理的使用剂量。这两个系统的推广使专家系统在医学领域迅速发展，在这个基础上后续也有其他系统推出，如 INTERNIST-I（一种计算机辅助诊断系统）^[50]、CADUCEUS（一种内科诊断咨询系统）^[51] 和 CASNET（描述疾病过程的因果关联的网络模型，主要用于青光眼的专家咨询计划）^[52] 等专家系统，但由于存在诸多问题而没有实现相关专业人员的常规使用^[53]。优秀决策的要求分为三点：准确数据、相关知识、适当解决问题的能力。数十年来基于计算机的决策辅助工作为临床医师提供了强大的动力^[54]，专家系统的领域局限性和被动性使人们意识到 CDSS 的重要性。CDSS 的不同之处在于它是以 EHR 的广泛普及为基础发展而成^[55]（图 3），同时融合了管理科学、运筹学、控制论和行为科学等多门学科，以计算机技术、仿真技术和信息技术为手段，支持决策活动的具有智能作用的人机系统，强调人机交互也是支持 CDSS 与从业人员工作流程相融洽的重要维度。近年来，越来越多地将其作为实用性工具，DNN 技术的革新和医疗保健的复杂性及其成本不可避免地增长，以及引入医疗保健立

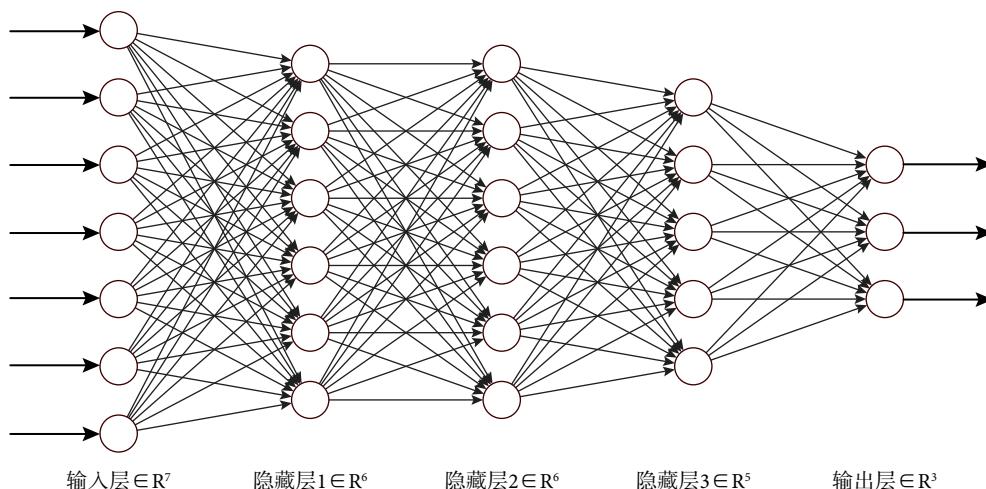


图 2 深度神经网络简化示意图

输入信息由输入层馈送，输入层又馈入一个或多个隐藏层，这些隐藏层最终链接到输出层，输入层以逐层非线性的方式处理馈入，以预先训练(初始化)后续隐藏层中的节点，从而学习“深层结构”和可概括的表示，之后这些表示被馈入到监督层中，并使用反向传播算法对整个网络进行微调，使其朝向针对特定端到端任务而作优化的表示^[28]

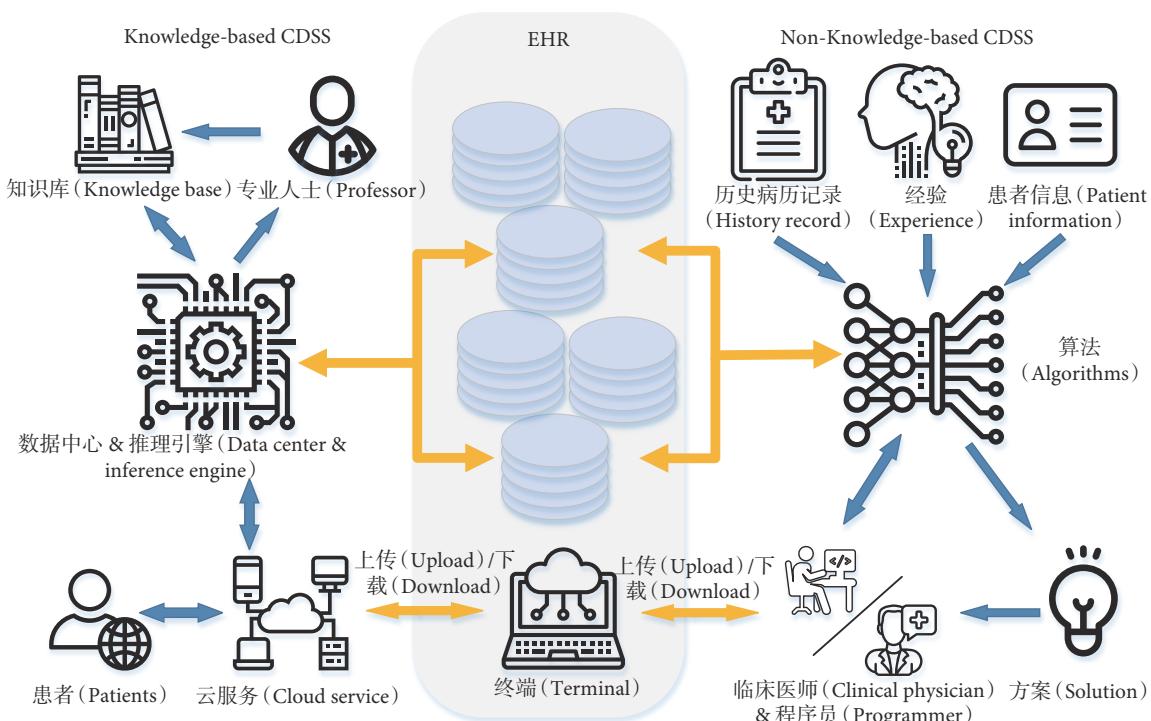


图 3 CDSS 的基本工作流程

CDSS 分为基于知识的系统和基于非知识的系统，前者主要包括三个部分：知识库、推理引擎和通信机制^[56]。知识库包含编译数据的规则和关联，这些关联和规则通常采用 If-then 规则运行；推理引擎使用健康记录、专业术语以及带有 CDS 规则的用户输入来执行决策支持逻辑；通信机制的功能是向用户界面显示警报时，接受临床医生的输入。基于非知识的 CDSS 是一种使用 ML 的人工智能形式，旨在从过去的经验中学习和/或在临床数据中找到相关模式。基于非知识的 CDSS 有三种算法：支持向量机、ANN 和遗传算法^[57]。CDSS：临床决策支持系统；EHR：电子健康病历；CDS：临床决策支持

法手段都促进了 CDSS 的发展^[58]。

1.4 自然语言处理

NLP 是 AI 的一个子领域，强调计算机与人类（自然）语言的交互，通过编写计算机程序来处理和分析人类书面和口头语言的能力。计算机认知

程序通过应用 NLP 来阅读快速增量的科学文献进行医学知识的学习和储备，利用医生的笔记和处方以及医学图像以提取有意义的见解和医疗保健的相关内容，并整理各种年份的电子病历从而致力于影响医疗实践来完善 EHR 大数据精准而快速的

管理^[59]。

1.5 计算机视觉

CV 是一个跨学科领域，同时也是 21 世纪发展速度最快的领域之一。CV 涉及如何使用机器从数字图像或视频中获得高层次的认知和理解，它以人类的方式从视频或图像中获取和学习信息。与医疗领域相关的主要内容包括医学图像和病理组织切片的自动扫描识别和分析^[60-61]，利用虚拟现实 (virtual reality, VR) 系统实现人体解剖结构的三维可视化功能从而为患者制定个性化手术方案^[62]，并且能为术者提供复杂手术的模拟指导导航功能^[63]，三维重建后的医学图像可通过 3D 打印模型用于术前手术策略规划、模拟手术的操控练习、医患之间病情沟通以及解剖指导教学资源^[64-66]。

2 人工智能技术在先天性心脏病学中的应用

早期 AI 应用于医学主要是通过使用计算机，将几种数学技术用于辅助医学诊断的某些方面：向医生提供与数据分析和鉴别诊断相关的定量方法；在诊断测试过程的各个阶段，协助评估最佳替代行动方案；定期记录和评估个体生理规范，以更敏感地确定个体相对于疾病预防的健康趋势^[67]。受限于算法模型和计算机性能的不足，早期诊断只能做到预估计算机正确诊断的后验概率，同时还要获得每种疾病的概率（即患者群体中患有每种疾病的人口比例）和给定疾病的每种症状子集的概率（即患有疾病的人也具有症状组合子集的比例）^[68]。随着数据矩阵的细化，计算机诊断的准确性仍在不断提高。计算机准备数据和接受计算机以鉴别诊断形式反馈的经验对于医生的诊断效率和正确性提高也有一定的作用。

2.1 智能诊断应用

智能诊断在 CHD 领域主要用于心脏杂音识别诊断和产前胎儿识别诊断。产前胎儿识别诊断主要用于 CHD 胎儿的妊娠期快速筛查，对于 CHD 的疾病防控和管理具有重要社会学意义。目前智能诊断技术主要依赖于 ML 和 DNN 模型。

2.1.1 心脏杂音识别诊断 CHD 部分病种的心脏杂音可辅助诊断，虽然该方法的诊断准确性不及影像学，但可作为一种初筛的手段用于推广普及至各个医院和诊所。该领域于八十年代推出专家系统^[69]。基于 CHD 不同病种心脏杂音的特异性，已经开发出了许多心脏杂音识别的智能模型。Barschdorff 使用神经网络进行心脏缺陷的语音记录并分析心音信号，从而实现类似于医生听诊心音信号后作出

的主观解释^[70]。神经网络的正确识别率可达 70%，若进一步积累数据可以提高诊断的准确性^[71]。隐马尔科夫模型 (hidden Markov models, HMM) 作为 NLP 应用程序中最常使用的统计模型，对于心脏杂音的识别，其总体分类正确率可达 96%，特异度 98%，该模型可快速筛选并进行特异性缺陷检测^[72]。Thompson 等^[73] 运用心脏听诊记录数据库选择病理性杂音、功能性杂音和无杂音的病例，研究基于 AI 的心脏杂音检测算法进行全面客观评估，加入算法确定性度量、患者年龄、心率、杂音强度、胸部记录位置和病理诊断等特征，准确率可达 88% (95%CI 85% ~ 91%)。这是首次利用大型数据库进行心脏杂音检测的全面评估，高敏感度和特异性使其可成为 CHD 潜在有用的筛选工具，并阐述了此类技术对于临床实用性的解释。

2.1.2 产前胎儿识别诊断 利用算法模型建立的诊断识别系统，对于产前诊断也具有重要意义。产前诊断有几率筛查尚未出生但患有复杂先天性心脏缺陷的胎儿，若病情严重可以考虑及时终止妊娠。Haghpanahi 等^[74] 设计了一种从非侵入性胎儿心电图信号中检测胎儿峰值的算法，该算法对临床遇到的各种不同形态和强度的信号都能很好地检测出胎儿 QRS 波的位置，可以帮助临床医生在分娩过程中做出更合适的决策方案。Yeo 等^[75] 报道了一种利用智能导航技术对 9 种标准胎儿超声心动图图像进行可视化的新的方法，该方法可标记包括胎儿心脏的七个解剖结构，简化了获取超声心动图视图所需的步骤，更少地依赖于操作人员，同时简化了对胎儿心脏的检查流程。通过超声智能导航检查胎儿心脏和无创胎儿心电图可以简化操作流程，使用较少的步骤即可得到需要的结果。临床医生运用 ML 或 CV 专业知识可以从不同的角度去实现此类技术，从而达到专业化诊断识别平台的目的。利用产前胎儿识别诊断技术和多中心区域化网络联合建立起 CHD 防控平台，有望从根源上降低 CHD 的发病率及患病率。在算法不断优化升级的同时，需要审核者拥有专业的基础知识并消除或规范主观偏见以避免误诊，做到客观公正、统一泛化的标准。

2.2 专家系统/临床决策支持系统

心音图 (phonocardiogram) 在早期应用是很多见的，其他的识别特征还有年龄、X 线检查、心电图、症状以及体格检查等，利用收集的所有患者资料推导出条件概率方程以表示临床医生从临床数据作出诊断的逻辑过程，并计算出每种疾病代表任何特定患者的正确诊断概率^[76]，或使用基于贝叶斯

概率模型用于 CHD 的诊断^[46,77-78], 疾病的诊断精度可与该领域经验丰富的专家相媲美。智能分类系统的设计是一个包含 2 500 多个条目的知识库, 用于描述 CHD 领域内的异常、治疗、并发症等, 结合特定领域知识和术语的目的是为数据输入和数据收集分析提供一个有用的工具^[79]。Vanisree 等^[80]利用 MATLAB 的图形用户界面特性, 结合反向传播神经网络设计开发的一种用于 CHD 诊断的决策支持系统, 其诊断精确度高达 90%。Leão 等^[81]使用决策树算法通过专家知识获取致力于建立一个 CHD 诊断研究专家系统, 试图推理出医生诊断 12 种常见 CHD 的启发式规则。Fallot 模型旨在解决诊断多个相互作用缺陷的难题, 单一缺陷的诊断正确率表现很完美, 合并缺陷的正确诊断率也能接近专家水平, 此方法的分类和分析可用于其他具有复杂相互作用的诊断任务^[82]。基于病例推理与神经网络相结合的诊断系统在解决新问题时, 神经网络用于做出假设并指导病例推理模块搜索之前类似病例并支持其中一个假设, 混合诊断系统可以解决神经网络无法以高精确度解决的问题, 此系统已用于开发 CHD 的诊断系统^[83]。对于医疗行业而言, 智能风险检测是一个具有挑战性的领域, Moghimi 等^[84]推出了可以实时智能检测并与医疗保健环境中的决策支持相结合的 CHD 智能风险监测模型, 模型的决策过程分为 3 个阶段, 医生和患者父母都可以参与决策, 包括手术过程和术后护理记录以及病历档案记录, 所有决策结果和医疗记录都会帮助患者进行实时风险监测并辅助作出相应的临床决策。医疗保健模式的转变促进了 CDSS 的发展和升级, 这些系统将与临床医生一起工作而非替代或转换。此外, 基于计算机的 EHR、互联网以及共享的决策流程和现行法规也有助于完善 CDSS。临床医生也越来越多地为这些工具开发做出贡献, 而不仅仅是参与用户体验。新技术包括互联网和软件的联合使用, 将彻底改变未来提供决策支持的方式。

2.3 预测

近年来, 诸如 DL 的技术正在快速发展, 尤其是 ML 方法更加适用于临床数据结构的预测和评估。ML 可以利用诊断系统比人类更快、更准确地检测疾病。Laitinen 等^[85]基于回归和 ANN 的方法通过 CHD 患者术前氧分压预测耗氧量, 但由于 CHD 患者个体间生物学变异性大, 进行建模以预测耗氧量较为复杂, 导致不能准确预测 CHD 患者的术前耗氧量。此外, 可预测紫绀型 CHD 术后患者的脑容量以评估手术对青少年患者的大脑发育

和长期功能的影响^[86], 或是通过预测 CHD 手术后运动和认知结果对风险较高的患者尽早实施干预^[87]。预测不仅仅适用于临床数据, 同样也可用于基因组数据。Bahado-Singh 等^[88]报道了人工智能结合表观基因组学首次用于 CoA 的预测, 并取得了较高的准确率。利用基于 ML 方法的线性支持向量机预测修复后法洛四联症患者的心室大小和功能的恶化, 从而研究心脏磁共振成像衍生的基线变量预测值, 并提供识别有恶化风险患者的模型^[89]。ML 方法适合基于现有数据做出预测, 但是对于遥远未来的精确预测往往是不可能的。因此, 临床实现的最终关键一步落在了更为紧要的目标上: 足够早地预测事件, 利用精确、适当的干预影响医疗决策与结局。

2.4 图像智能识别和分割

卷积神经网络系统 (convolutional neural network system, CNN) 对于图像识别有出色优势, 它们的容量可以通过改变深度和宽度来进行控制, 并且它们也能对图像的性质做出强有力且基本正确的假设^[90], 所以诸如 DL 之类的 ML 技术迅速发展。

各种成像方式为 CHD 患者提供诊断信息。心脏磁共振 (cardiac magnetic resonance, CMR) 和心脏计算机断层扫描血管造影 (computed tomography angiography, CTA) 以及超声心动图 (ultrasonic cardiogram, UCG) 是最常用的工具。Vitanovski^[91]提出了一种基于鲁棒性 ML 算法的分层框架来估计个性化模型参数用于自动分割胸主动脉和主要分支腔脉, 主要用于主动脉缩窄 (coarctation of aorta, CoA) 和主动脉瓣二瓣叶畸形 (bicuspid aortic valve defect, BAVD) 的患者, 基于个性化模型的精确测量有助于选择最佳治疗方案、术者决策和修复时机。在超声心动图中, ML 方法已经被应用于心肌运动速度评估^[92]、左心室边界分割^[93]、M 型和 B 型超声心动图中心脏参数的测量^[94]、自动检测左心室边界^[95]、自动识别超声心动图视图^[96]以及室壁异常运动的量化^[97-98]等方面。右心室分割是一个不易解决的问题, 与左心室相比, 右心室的分割存在许多困难, 例如复杂的新月形结构、小梁化心肌的存在和相对较薄的心室壁。受到 CNN 强大的图像处理能力的启发^[99], 研究人员提出了基于 CNN 的右心室分割方法。Luo 等^[100]提出一种利用深度 CNN 解决 CMR 中右心室分割问题的新方法, 基于兴趣区域定位进行右心室心肌分割, 该方法在一定程度上提高了分割精度和计算效率。Tran 等^[101]提出了一种基于完全 CNN 用于短轴 CMR 心脏分割的方法, 可以同时处理左心室和右心室的分割问题。还可

使用扩展 CNN 自动分割 CHD 心血管 MR 图像, 该方法能够准确地分割心肌和血池而无需任何专业人员的干预^[102]。许多心脏测量工具可以实现心室划分和自动分割的模式, 并且它们已经提高了诊断质量, 用于复杂 CHD 患者的潜在诊断和长期随访检查工作^[103]。在心脏医学图像方面进行智能识别和分割分析的基础上, 目前已经实现心脏三维结构的 VR 和增强现实用于 CHD 复杂手术的规划指导和导航功能^[104-105]。VR 部分的主要应用是 VR 系统, 增强现实部分的主要应用是 3D 打印(又叫增材制造), 二者的结合应用称为混合现实(mixed reality, MR)技术。这两个部分都非 AI 领域的发展学科, 但借助于 CV 技术的强大功能可以呈现出临床医生需要的虚拟或实体三维心脏解剖模型, 对于先天性心脏病学具有重要意义。无论是 VR 系统或是 3D 打印, 都需要心脏 CTA、超声心动图或 CMR 的图像经过分割和重建才能呈现出一个三维立体数字可视化模型, 用于不同的途径(图 4)。此技术作为心脏三维结构模型的基础, 借助深度学习神经网络的强大功能可以实现自动化心脏图像分析^[106-110], 从而实现 CHD 不同病种的自动化诊断功能。

在临床影像数据量足够的前提下, ML 可以通

过调整训练集和测试集的比例以学习并识别医学图像, 对于复杂性和变异性高的疑难病例, 图像分割技术可以帮助机器做出判断, 优化机器在识别过程中的质量和速度, 从而达到专业人员的判读标准。图像智能识别技术可以帮助影像从业人员快速阅读医学图像的结果, 并作出正确的判读决定, 同时减少从业人员的工作强度以服务于更多的患者。不同学科领域应用 AI 的效果和途径都有所不同, 在医学方面应用 AI 比较成功的肺癌领域, 医学成像和 AI 有望通过区分良性结节和恶性结节, 在提高肺癌的早期发现和定性方面发挥重要作用, 可以很好地改善大部分患者的预后, 以降低肺癌死亡率^[111]。根据研究结果显示, 使用深度 CNN 在低剂量下胸部 CT 扫描发现恶性肺结节的模型曲线下面积(area under curve, AUC)高达 94.4%, 在没有 CT 的条件下, 模型的表现优于放射科医师; 而在拥有 CT 的条件下, 模型的性能可与放射科医师相当^[112]。究其原因在于肺癌的筛查基本手段是使用低剂量胸部 CT 进行扫描检查, 可以有效降低肺癌死亡率^[113-114], 并且因为低剂量的缘故对人体产生的辐射危害较小且阳性筛查率高, 目前已经取代胸部 X 线片检查手段。而心脏 CTA 需要使用血管造影剂才能清晰

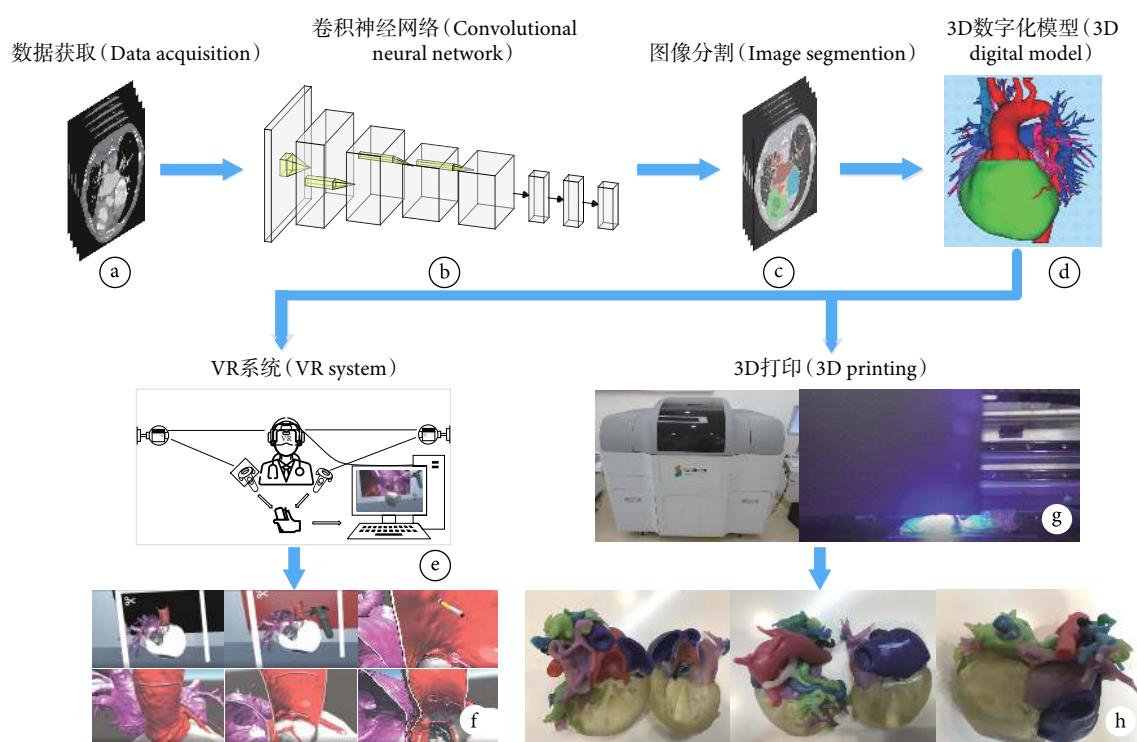


图 4 心脏医学影像的三维建模用于 VR 系统或 3D 打印的简化示意图

a ~ d: 心脏 CTA 或 CMR 及超声心动图的影像数据收集后, 利用建模软件的智能图像识别和分割功能生成三维立体数字化模型; e: 使用 VR 系统读取生成后的心脏图像建模数据, 头戴显示器与主机连接, 通过空间定位器进行感应, 利用控制手柄操控虚拟空间中的三维模型; f: VR 系统操作下演示 1 例冠状动脉瘤病例的手术部位标记; g: 3D 打印机和心脏三维模具打印; h: 心脏 3D 打印模具效果演示; VR: 虚拟现实; CTA: 计算机断层扫描血管造影; CMR: 心脏磁共振

显现出各个部分的心脏组织,因为CHD多发于儿童,需要对造影剂的剂量控制得更加精确并在最大程度上减少辐射对患儿的危害。AI在肺癌方面的成功应用值得我们借鉴学习,CHD的医工结合之路任重而道远。

3 总结

正在进行的AI技术革命为CHD领域提供了一个积极的引导趋势,我们希望AI,包括但不限于ML以及DL,可以对医学领域的各个学科产生积极深远的影响。但为了做到这一点,需要尽快弥补AI虚拟世界与临床医学现实之间的差距,AI技术应用如此广泛,与医疗领域相互交叉形成多门学科,二者相互学习,但医学的复杂性和伦理限制需要更多的发展空间去迎合和接受AI技术的改造,我们应当抱以合理的期望和严谨的态度。未来的智能软件将占据更加主要的地位,比如更加真实且易于操作的多维VR技术,方便临床医师理解和使用,同时以科学合理的方式重复多次使用神经网络来更快更高效地做出决策,并减少相关学科操作人员的工作,使他们能够专注于自己的核心竞争力,可以将更多的时间用于照顾患者。使用AI的目的并非替代临床工作人员,二者应该通过相互学习从而促进双方共同进步,通过深度神经网络学习系统和AI相结合的强大推理能力用以改善CDSS的可靠性和稳定性。AI正在医学领域创造一个从基础研究到临床应用的转变,但仍有一些技术挑战有待解决,需要谨慎对待。数据安全和对抗性攻击等漏洞对AI技术的应用构成了潜在的威胁,在这些漏洞中,恶意操纵输入可能会导致完全的误诊,从而被用于谋取欺诈性利益等不正当行为^[15]。在强调人机交互和用户反馈的同时,也要注重加入关键技术以保护用户和患者的隐私安全。为了并行AI与先天性心脏病学专业的发展进程,完善医疗行业的AI相关伦理法规和市场安全监管是非常必要的。不同于AI在肺癌方面的成功应用以及广泛普及,CHD各个病种分型数目可达上百种之多,不同中心对于不同病种的手术策略也各有异同。我们应该专注于自身的专业特性,未来的CHD方向应该是以医工结合的方式快速发展,通过各种智能识别诊断模型建立起CHD多中心区域化防治防控网络以降低发病率,使用CNN智能图像处理和分析技术实现自动化重建心脏三维可视化模型,辅助心脏外科医师制定个性化手术治疗方案和术前病情讨论及规划,同时利用各种术前术后的临床大样本数

据辅助医师做出临床决策并结合患者的当前病情做出风险预估评测。AI在先天性心脏病学领域具有强大的临床诊疗价值和应用潜力。

利益冲突:无。

参考文献

- Sissman NJ. Incidence of congenital heart disease. *JAMA*, 2001, 285(20): 2579-2580.
- van der Linde D, Konings EE, Slager MA, et al. Birth prevalence of congenital heart disease worldwide: a systematic review and meta-analysis. *J Am Coll Cardiol*, 2011, 58(21): 2241-2247.
- 朱军,周光萱,代礼,等.1996~2000年全国围产期先天性心脏病发生率的分析.四川大学学报(医学版),2004,35(6):875-877.
- Mendis S, Puska P, Norrvig B, et al. Global atlas on cardiovascular disease prevention and control. Geneva: World Health Organ, 2011.
- Connor JM. Genetic disorders and the fetus. Diagnosis, prevention and treatment. *J Med Genet*, 1993, 30(4): 351.
- Hoffman JI, Kaplan S. The incidence of congenital heart disease. *J Am Coll Cardiol*, 2002, 39(12): 1890-1900.
- Marelli AJ, Ionescu-Ittu R, Mackie AS, et al. Lifetime prevalence of congenital heart disease in the general population from 2000 to 2010. *Circulation*, 2014, 130(9): 749-756.
- Diller G, Kempny A, Alonso-Gonzalez R, et al. Survival prospects and circumstances of death in contemporary adult congenital heart disease patients under follow-up at a large tertiary centre. *Circulation*, 2015, 132(22): 2118-2125.
- Yu C, Moore BM, Kotchetkova I, et al. Causes of death in a contemporary adult congenital heart disease cohort. *Heart*, 2018, 104(20): 1678-1682.
- Oster ME, Strickland MJ, Mahle WT. Impact of prior hospital mortality versus surgical volume on mortality following surgery for congenital heart disease. *J Thorac Cardiovasc Surg*, 2011, 142(4): 882-886.
- Apfeld JC, Kastenberg ZJ, Gibbons AT, et al. The disproportionate cost of operation and congenital anomalies in infancy. *Surgery*, 2019.
- Russo CA, Elixhauser A. Hospitalizations for birth defects, 2004: Statistical Brief #24. Rockville: Agency for Healthcare Research and Quality, 2006.
- 陈英耀,张洁,李军,等.先天性心脏病的疾病经济负担研究. *中华医院管理杂志*, 2007, 23(11): 740-744.
- 陈英耀.我国主要出生缺陷的疾病负担和预防措施的经济学评价研究.复旦大学,2006.
- Moore GE. Cramming more components onto integrated circuits. *P IEEE*, 1998, 86(1): 82-85.
- Hinton GE, Osindero S, Teh Y. A fast learning algorithm for deep belief nets. *Neural Comput*, 2006, 18(7): 1527-1554.
- Mitchell TM. Machine learning. 1997. Burr Ridge, IL: McGraw Hill, 1997, 45(37): 870-877.
- Jordan MI, Mitchell TM. Machine learning: Trends, perspectives, and prospects. *Science*, 2015, 349(6245): 255-260.
- McCulloch WS, Pitts W. A logical calculus of the ideas immanent in nervous activity. *Bull Math Biophys*, 1943, 5(4): 115-133.
- Hebb DO. The organization of behavior: a neuropsychological theory. Science Editions, 1962.

- 21 Rosenblatt F. The perceptron: a probabilistic model for information storage and organization in the brain. *Psychol Rev*, 1958, 65(6): 386.
- 22 Widrow B, Hoff ME. Adaptive switching circuits, in neurocomputing: foundations of research. Cambridge: MIT Press, 1988. 123-134.
- 23 Haykin S. Neural networks: a comprehensive foundation. Prentice Hall PTR, 1994.
- 24 Schmidhuber J. Deep learning in neural networks: An overview. *Neural Networks*, 2015, 61: 85-117.
- 25 Bengio Y, Goodfellow I, Courville A. Deep learning. Citeseer, 2017.
- 26 Bengio Y, Courville A, Vincent P. Representation learning: A review and new perspectives. *IEEE Trans Pattern Anal Mach Intell*, 2013, 35(8): 1798-1828.
- 27 LeCun Y, Bengio Y, Hinton G. Deep learning. *Nature*, 2015, 521(7553): 436-444.
- 28 Miotto R, Wang F, Wang S, et al. Deep learning for healthcare: review, opportunities and challenges. *Brief Bioinform*, 2017, 19(6): 1236-1246.
- 29 Najafabadi MM, Villanustre F, Khoshgoftaar TM, et al. Deep learning applications and challenges in big data analytics. *J Big Data*, 2015, 2(1): 1.
- 30 Haberl MG, Churas C, Tindall L, et al. CDDeep3M-Plug-and-Play cloud-based deep learning for image segmentation. *Nat Methods*, 2018, 15(9): 677.
- 31 Sullivan DP, Winsnes CF, Åkesson L, et al. Deep learning is combined with massive-scale citizen science to improve large-scale image classification. *Nat Biotechnol*, 2018, 36(9): 820.
- 32 Strack R. Deep learning advances super-resolution imaging. *Nat Methods*, 2018, 15(6): 403.
- 33 Fang S, Tsao Y, Hsiao M, et al. Detection of pathological voice using cepstrum vectors: A deep learning approach. *J Voice*, 2019, 33(5): 634-641.
- 34 Chen MC, Ball RL, Yang L, et al. Deep learning to classify radiology free-text reports. *Radiology*, 2017, 286(3): 845-852.
- 35 Cho K, Van Merriënboer B, Gulcehre C, et al. Learning phrase representations using RNN encoder-decoder for statistical machine translation. Conference on empirical methods in natural language processing, 2014.
- 36 Ting DSW, Cheung CY, Lim G, et al. Development and validation of a deep learning system for diabetic retinopathy and related eye diseases using retinal images from multiethnic populations with diabetes. *JAMA*, 2017, 318(22): 2211-2223.
- 37 Gargyea R, Leng T. Automated identification of diabetic retinopathy using deep learning. *Ophthalmology*, 2017, 124(7): 962-969.
- 38 Zheng Q, Delingette H, Duchateau N, et al. 3-D consistent and robust segmentation of cardiac images by deep learning with spatial propagation. *IEEE Trans Med Imaging*, 2018, 37(9): 2137-2148.
- 39 Bejnordi BE, Veta M, van Diest PJ, et al. Diagnostic assessment of deep learning algorithms for detection of lymph node metastases in women with breast cancer. *JAMA*, 2017, 318(22): 2199-2210.
- 40 Coudray N, Ocampo PS, Sakellaropoulos T, et al. Classification and mutation prediction from non-small cell lung cancer histopathology images using deep learning. *Nat Med*, 2018, 24(10): 1559.
- 41 Zhou J, Park CY, Theesfeld CL, et al. Whole-genome deep-learning analysis identifies contribution of noncoding mutations to autism risk. *Nat Genet*, 2019, 51(6): 973.
- 42 Chaudhary K, Poirion OB, Lu L, et al. Deep learning-based multi-omics integration robustly predicts survival in liver cancer. *Clin Cancer Res*, 2018, 24(6): 1248-1259.
- 43 Miotto R, Li L, Kidd BA, et al. Deep patient: an unsupervised representation to predict the future of patients from the electronic health records. *Sci Rep-Uk*, 2016, 6: 26094.
- 44 Liang H, Tsui BY, Ni H, et al. Evaluation and accurate diagnoses of pediatric diseases using artificial intelligence. *Nat Med*, 2019, 25(3): 433.
- 45 Ledley RS, Lusted LB. Reasoning foundations of medical diagnosis; symbolic logic, probability, and value theory aid our understanding of how physicians reason. *Science*, 1959, 130(3366): 9-21.
- 46 Warner HR, Toronto AF, Veasy LG. Experience with Baye's theorem for computer diagnosis of congenital heart disease. *Ann N Y Acad Sci*, 1964, 115(2): 558-567.
- 47 Bleich HL. Computer-based consultation: electrolyte and acid-base disorders. *Am J Med*, 1972, 53(3): 285-291.
- 48 Lederberg J. DENDRAL-64: A system for computer construction, enumeration and notation of organic molecules as tree structures and cyclic graphs, Part II : Topology of cyclic graphs. 1965.
- 49 Shortliffe EH. MYCIN: a rule-based computer program for advising physicians regarding antimicrobial therapy selection. Stanf Univ Calif Dept of Comput Sci, 1974.
- 50 Miller RA, Pople Jr HE, Myers JD. Internist- I , an experimental computer-based diagnostic consultant for general internal medicine. *N Engl J Med*, 1982, 307(8): 468-476.
- 51 Myers JD, Pople HE, Miller RA. CADUCEUS: a computerized diagnostic consultation system in internal medicine, 1982. Am Med Inform Assoc, 1982.
- 52 Kulikowski CA, Weiss SM. Representation of expert knowledge for consultation: the CASNET and EXPERT projects. *Artif Intell Med*, 1982: 51.
- 53 Miller RA. INTERNIST-1/CADUCEUS: problems facing expert consultant programs. *Methods Inf Med*, 1984, 23(1): 9-14.
- 54 Kawamoto K, Houlihan CA, Balas EA, et al. Improving clinical practice using clinical decision support systems: a systematic review of trials to identify features critical to success. *BMJ*, 2005, 330(7494): 765.
- 55 Castaneda C, Nalley K, Mannion C, et al. Clinical decision support systems for improving diagnostic accuracy and achieving precision medicine. *J Clin Bioinforma*, 2015, 5(1): 4.
- 56 Soufi MD, Samad-Soltani T, Vahdati SS, et al. Decision support system for triage management: A hybrid approach using rule-based reasoning and fuzzy logic. *Int J Med Inform*, 2018, 114: 35-44.
- 57 Wagholarik KB, Sundararajan V, Deshpande AW. Modeling paradigms for medical diagnostic decision support: a survey and future directions. *J Med Syst*, 2012, 36(5): 3029-3049.
- 58 Musen MA, Middleton B, Greenes RA. Clinical decision-support systems. Springer, 2014: 643-674.
- 59 Miller DD, Brown EW. Artificial intelligence in medical practice: The question to the answer? *Am J Med*, 2018, 131(2): 129-133.
- 60 Lambin P, Rios-Velazquez E, Leijenaar R, et al. Radiomics: extracting more information from medical images using advanced



- feature analysis. *Eur J Cancer*, 2012, 48(4): 441-446.
- 61 Niazi MKK, Parwani AV, Gurcan MN. Digital pathology and artificial intelligence. *Lancet Oncol*, 2019, 20(5): e253-e261.
- 62 Reitinger B, Schmalstieg D, Bornik A, et al. Spatial analysis tools for virtual reality-based surgical planning, 2006. IEEE, 2006.
- 63 Mazzoni S, Badiali G, Lancellotti L, et al. Simulation-guided navigation: a new approach to improve intraoperative three-dimensional reproducibility during orthognathic surgery. *J Craniofac Surg*, 2010, 21(6): 1698-1705.
- 64 Li C, Cheung TF, Fan VC, et al. Applications of three-dimensional printing in surgery. *Surg Innov*, 2017, 24(1): 82-88.
- 65 McMenamin PG, Quayle MR, McHenry CR, et al. The production of anatomical teaching resources using three-dimensional (3D) printing technology. *Anat Sci Educ*, 2014, 7(6): 479-486.
- 66 Malik HH, Darwood AR, Shaunak S, et al. Three-dimensional printing in surgery: a review of current surgical applications. *J Surg Res*, 2015, 199(2): 512-522.
- 67 Ledley RS, Lusted LB. The use of electronic computers to aid in medical diagnosis. *Proc Inst Radio Eng*, 1959, 47(11): 1970-1977.
- 68 Vanderplas JM. A method for determining probabilities for correct use of Bayes's theorem in medical diagnosis. *Comput Biomed Res*, 1967, 1(3): 215-220.
- 69 Johnson PE, Nachtsheim CJ, Zualkernan IA. Consultant expertise. *Expert Syst*, 1987, 4(3): 180-195.
- 70 Barschdorff D, Ester S, Dorsel T, et al. Phonographic diagnostic aid in heart defects using neural networks. *Biomedizinische Technik. Biomed Eng*, 1990, 35(11): 271-279.
- 71 Higuchi K, Sato K, Makuuchi H, et al. Automated diagnosis of heart disease in patients with heart murmurs: application of a neural network technique. *J Med Eng Technol*, 2006, 30(2): 61-68.
- 72 Kotb MA, Nabih H, El Zahraa F, et al. Improving the recognition of heart murmur. *Int J Adv Comput Sci Appl*, 2016, 7(7): 283-287.
- 73 Thompson WR, Reinisch AJ, Unterberger MJ, et al. Artificial intelligence-assisted auscultation of heart murmurs: validation by virtual clinical trial. *Pediatr Cardiol*, 2019, 40(3): 623-629.
- 74 Haghpansahi M, Borkholder DA. Fetal QRS extraction from abdominal recordings via model-based signal processing and intelligent signal merging. *Physiol Meas*, 2014, 35(8): 1591.
- 75 Yeo L, Romero R. Fetal intelligent navigation echocardiography (FINE): a novel method for rapid, simple, and automatic examination of the fetal heart. *Ultrasound Obstet Gynecol*, 2013, 42(3): 268-284.
- 76 Warner HR, Toronto AF, Veasey LG, et al. A mathematical approach to medical diagnosis: application to congenital heart disease. *JAMA*, 1961, 177(3): 177-183.
- 77 Templeton AW, Lehr JL, Simmons C. The computer evaluation and diagnosis of congenital heart disease, using roentgenographic findings. *Radiology*, 1966, 87(4): 658-670.
- 78 Reale A, Maccacaro GA, Rocca E, et al. Computer diagnosis of congenital heart disease. *Comput Biomed Res*, 1968, 1(6): 533-549.
- 79 Timmers T, Dingemans PJ, Hess J. Smart classification system (SmaCS): design, implementation, and application for congenital heart disease terminology. *Medinfo*, 1995, 8: 167-171.
- 80 Vanisree K, Jyothi S. Decision support system for congenital heart disease diagnosis based on signs and symptoms using neural networks. *Int J Comput Appl*, 2011: 19.
- 81 Leão FB, Rocha FA. Proposed methodology for knowledge acquisition: a study on congenital heart disease diagnosis. *Methods Inf Med*, 1990, 29(1): 30-40.
- 82 Reed NE, Gini M, Johnson PE, et al. Diagnosing congenital heart defects using the Fallot computational model. *Artif Intell Med*, 1997, 10(1): 25-40.
- 83 Reategui EB, Campbell JA, Leao BF. Combining a neural network with case-based reasoning in a diagnostic system. *Artif Intell Med*, 1997, 9(1): 5-27.
- 84 Moghimi F, Wickramasinghe N, Zadeh HS. An intelligence risk detection framework to improve decision efficiency in healthcare contexts: The example of pediatric congenital heart disease, 2011. IEEE, 2011.
- 85 Laitinen PO, Räsänen J. Measured versus predicted oxygen consumption in children with congenital heart disease. *Heart*, 1998, 80(6): 601-605.
- 86 von Rhein M, Buchmann A, Hagmann C, et al. Brain volumes predict neurodevelopment in adolescents after surgery for congenital heart disease. *Brain*, 2013, 137(1): 268-276.
- 87 Snookes SH, Gunn JK, Eldridge BJ, et al. A systematic review of motor and cognitive outcomes after early surgery for congenital heart disease. *Pediatrics*, 2010, 125(4): e818-e827.
- 88 Bahado-Singh R, Vishweswaraiyah S, Sayed N, et al. Deep learning/artificial intelligence and the epigenomic prediction of coarctation of the aorta. *Am J Obstet Gynecol*, 2019, 220(1).
- 89 Samad MD, Wehner GJ, Arbabshirani MR, et al. Predicting deterioration of ventricular function in patients with repaired tetralogy of Fallot using machine learning. *Eur Heart J Cardiovasc Imaging*, 2018, 19(7): 730-738.
- 90 Krizhevsky A, Sutskever I, Hinton GE. Imagenet classification with deep convolutional neural networks. *Adv Neural Inf Process Syst*, 2012: 1097-1105.
- 91 Vitanovski D, Ralovich K, Ionasec R, et al. Personalized learning-based segmentation of thoracic aorta and main branches for diagnosis and treatment planning, 2012. IEEE, 2012.
- 92 Sanchez-Martinez S, Duchateau N, Erdei T, et al. Characterization of myocardial motion patterns by unsupervised multiple kernel learning. *Med Image Anal*, 2017, 35: 70-82.
- 93 Carneiro G, Nascimento JC, Freitas A. The segmentation of the left ventricle of the heart from ultrasound data using deep learning architectures and derivative-based search methods. *IEEE Trans Image Process*, 2011, 21(3): 968-982.
- 94 Park J, Feng S, Zhou SK. Automatic computation of 2D cardiac measurements from B-mode echocardiography, 2012. *Int Soc Opt Photonics*, 2012.
- 95 Belous G, Busch A, Rowlands D. Segmentation of the left ventricle from ultrasound using random forest with active shape model, 2013. IEEE, 2013.
- 96 Madani A, Arnaout R, Mofrad M, et al. Fast and accurate view classification of echocardiograms using deep learning. *NPJ Digit Med*, 2018, 1(1): 6.
- 97 Omar HA, Domingos JS, Patra A, et al. Quantification of cardiac bull's-eye map based on principal strain analysis for myocardial wall motion assessment in stress echocardiography, 2018. IEEE, 2018.
- 98 Raghavendra U, Fujita H, Gudigar A, et al. Automated technique for coronary artery disease characterization and classification using DD-DTDWT in ultrasound images. *Biomed Signal Process Control*, 2018, 40: 324-334.



- 99 Shin H, Roth HR, Gao M, et al. Deep convolutional neural networks for computer-aided detection: CNN architectures, dataset characteristics and transfer learning. *IEEE Trans Med Imaging*, 2016, 35(5): 1285-1298.
- 100 Luo G, An R, Wang K, et al. A deep learning network for right ventricle segmentation in short-axis MRI, 2016. IEEE, 2016.
- 101 Tran PV. A fully convolutional neural network for cardiac segmentation in short-axis MRI. arXiv: 1604.00494, 2016.
- 102 Wolterink JM, Leiner T, Viergever MA, et al. Dilated convolutional neural networks for cardiovascular MR segmentation in congenital heart disease. Springer, 2016: 95-102.
- 103 Diller G, Babu-Narayan S, Li W, et al. Utility of machine learning algorithms in assessing patients with a systemic right ventricle. *Eur Heart J Cardiovasc Imaging*, 2019, 20(8): 925-931.
- 104 Cantinotti M, Valverde I, Kutty S. Three-dimensional printed models in congenital heart disease. *Int J Cardiovasc Imaging*, 2017, 33(1): 137-144.
- 105 Ong CS, Krishnan A, Huang CY, et al. Role of virtual reality in congenital heart disease. *Congenit Heart Dis*, 2018, 13(3): 357-361.
- 106 Bai W, Sinclair M, Tarroni G, et al. Automated cardiovascular magnetic resonance image analysis with fully convolutional networks. *J Cardiovasc Magn Reson*, 2018, 20(1): 65.
- 107 Avendi MR, Kheradvar A, Jafarkhani H. A combined deep-learning and deformable-model approach to fully automatic segmentation of the left ventricle in cardiac MRI. *Med Image Anal*, 2016, 30: 108-119.
- 108 Zreik M, Leiner T, De Vos BD, et al. Automatic segmentation of the left ventricle in cardiac CT angiography using convolutional neural networks, 2016. IEEE, 2016.
- 109 Dormer JD, Ma L, Halicek M, et al. Heart chamber segmentation from CT using convolutional neural networks, 2018. Int Soc Opt Photonics, 2018.
- 110 Madani A, Ong JR, Tibrewal A, et al. Deep echocardiography: data-efficient supervised and semi-supervised deep learning towards automated diagnosis of cardiac disease. *NPJ Digit Med*, 2018, 1(1): 59.
- 111 Bi WL, Hosny A, Schabath MB, et al. Artificial intelligence in cancer imaging: Clinical challenges and applications. *CA Cancer J Clin*, 2019, 69(2): 127-157.
- 112 Ardila D, Kiraly AP, Bharadwaj S, et al. End-to-end lung cancer screening with three-dimensional deep learning on low-dose chest computed tomography. *Nat Med*, 2019, 25(6): 954-961.
- 113 Sobue T, Moriyama N, Kaneko M, et al. Screening for lung cancer with low-dose helical computed tomography: anti-lung cancer association project. *J Clin Oncol*, 2002, 20(4): 911-920.
- 114 National LSTR. Results of initial low-dose computed tomographic screening for lung cancer. *N Engl J Med*, 2013, 368(21): 1980-1991.
- 115 Finlayson SG, Bowers JD, Ito J, et al. Adversarial attacks on medical machine learning. *Science*, 2019, 363(6433): 1287-1289.

收稿日期：2019-11-30 修回日期：2019-12-27

本文编辑：刘雪梅，雷芳