

• 专家论坛 •

人工智能在心血管医学中的应用



邱海龙^{1,2}, 郭惠明^{1,2}, 姚泽阳^{1,2}, 谢稳^{1,2}, 徐小维², 黄美萍², 岑坚正^{1,2}, 庄建^{1,2}

1. 广东省人民医院(广东省医学科学院) 广东省心血管病研究所 心外科(广州 510080)

2. 广东省人民医院(广东省医学科学院) 广东省华南结构性心脏病重点实验室 心血管人工智能与三维技术实验室(广州 510080)

【摘要】 心血管疾病是全球导致死亡的首要原因,其诊治非常依赖各种临床数据。随着医疗大数据时代的到来,人工智能在心血管医学中的影像、诊断和预后预测等多个方面得到广泛应用,为精准诊治提供了新的方法。本文综述了人工智能在心血管医学中的应用现状。

【关键词】 人工智能; 心血管疾病; 机器学习; 预测模型; 综述

Application of artificial intelligence in cardiovascular medicine

QIU Hailong^{1,2}, GUO Huiming^{1,2}, YAO Zeyang^{1,2}, XIE Wen^{1,2}, XU Xiaowei², HUANG Meiping², CEN Jianzheng^{1,2}, ZHUANG Jian^{1,2}

1. Department of Cardiovascular Surgery, Guangdong Cardiovascular Institute, Guangdong Provincial People's Hospital, Guangdong Academy of Medical Sciences, Guangzhou, 510080, P.R.China

2. Laboratory of Artificial Intelligence and 3D Technologies for Cardiovascular Diseases, Guangdong Provincial Key Laboratory of South China Structural Heart Disease, Guangdong Provincial People's Hospital, Guangdong Academy of Medical Sciences, Guangzhou, 510080, P.R.China

Corresponding author: ZHUANG Jian, Email: Zhuangjian5413@163.com

【Abstract】 Cardiovascular diseases are the leading cause of death and their diagnosis and treatment rely heavily on the variety of clinical data. With the advent of the era of medical big data, artificial intelligence (AI) has been widely applied in many aspects such as imaging, diagnosis and prognosis prediction in cardiovascular medicine, providing a new method for accurate diagnosis and treatment. This paper reviews the application of AI in cardiovascular medicine.

【Key words】 Artificial intelligence; cardiovascular disease; machine learning; prediction model; review

Foundation items: Science and Technology Planning Project of Guangdong Province (2019B020230003; 2017A070701013; 2017B090904034; 2017B030314109; 2018B090944002); Guangdong Peak Project (DFJH201802); National Key Research and Development Program (2018YFC1002600)

心血管疾病是全球导致死亡的首要原因^[1],在中国,40%以上的死亡与之相关^[2]。为了减少心血管疾病带来的死亡和不良影响,提升患者的预期寿命和改善患者的生活质量,尽早预测和提升诊治水平显得同样重要。预测方面,过往有研究者基于有限的明确的风险因素,例如高血压、高血脂、吸烟、糖尿病和年龄等,提出过几种心血管疾病预测模型^[3-6],但是预测效能均显不足,特异性和敏感性尚有待提高,难以做到个性化精准预测。随着人们对

健康的日益重视、就医行为的改变,以及各种随身设备发展和流行,越来越多的相关数据将被记录下来,形成健康大数据,这些数据都有可能与心血管疾病的发生相关,都应该纳入分析。诊治方面,一直以来都非常依赖各种检查,包括心电图和各种影像检查等,这些检查数据量日益剧增,同时,临床病历电子化程度越来越高,诊治过程中越来越多临床数据被格式化或者非格式化记录下来,形成了临床大数据。不管是基于健康大数据的预测,还是基于临床大数据的诊治,都严重依赖于有经验的医师。然而,在巨大的病例数和数据量前,医生的数量、精力、时间和处理数据的能力都严重不足。随着硬件的发展,机器计算力呈指数增长,人工智能(artificial intelligence, AI)兴起,为医疗大数据的处

DOI: 10.7507/1007-4848.202103107

基金项目: 广东省科技计划项目(2019B020230003; 2017A070701013; 2017B090904034; 2017B030314109; 2018B090944002); 广东省登峰计划项目(DFJH201802); 国家重点研发计划(2018YFC1002600)

通信作者: 庄建, Email: Zhuangjian5413@163.com



<http://www.tcsurg.org>

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. <http://www.cnki.net>

理和挖掘提供了新的可能。本文综述了 AI 在心血管医学中的应用现状。

1 人工智能

AI 属于计算机科学下面的一个分支，旨在模仿人类的认知功能，泛指能够通过获取广泛的知识后，自行获得推理和思考能力的通用系统。机器学习 (machine learning, ML) 是目前医学领域应用最广泛的 AI 方法，它可以直接分析大型、复杂且不同种类的数据，给出相应的解释或者预测。ML 通常包含三个步骤——数据的准备、模型的选择与训练和模型验证。按照学习方法，它可以大致分为监督学习 (supervised learning)、非监督学习 (unsupervised machine learning) 和强化学习 (reinforcement learning)。监督学习指的是研究者使用带有标记结果或类别的观察数据来训练模型，从而对事物进行分类或对未来的事件进行预测。常用的监督学习算法包括朴素贝叶斯定理 (Naïve Bayes theorem)、K-近邻算法 (K-nearest neighbors, KNN)、支持向量机 (support vector machine, SVM)、随机森林 (random forest, RF)、极端梯度提升 (extreme gradient boosting, XGBoost)、决策树 (decision tree) 等。非监督学习指的是研究者直接利用无标记的原始数据训练模型，让算法本身去学习数据的内在结构和规律。常用的非监督学习算法包括均值聚类 (K-means clustering)、分层聚类 (hierarchical clustering)、主成分分析 (principal component analysis)、奇异值分解 (singular value decomposition) 等。强化学习是基于行为心理学的 ML 的另一个新兴分支学科。强化学习不要求预先给定任何数据，而是通过接收环境对动作的奖励 (反馈) 获得学习信息并更新模型参数。

ML 其中一个重要的分支是深度学习 (deep learning, DL)，它由多层深度神经网络 (deep neural network, DNN) 组成，输入相关数据，通过多层 DNN 的处理，最后可以输出相应的特征图。同样的，它也可以分为监督学习、非监督学习和强化学习。目前最具代表性的 DL 模型是卷积神经网络 (convolutional neural network, CNN)。DL 在图像分类、图像分割、自然语言处理、语音识别和基因组学中已经得到有效应用。

2 人工智能在心血管医学中的应用

2.1 影像学

2.1.1 图像采集和重建 超声心动图是心脏病学中应用最广泛的影像学方法。有公司已经开发出基于 DL 的实时导航软件，用于指导未经培训的用户

获取标准超声心动图视图，通过该软件，用户可以不断优化精确信号，从而不断地接近标准视图^[7]。这些 DL 模型可以自动分析获取的图像数据集来识别和标注心脏解剖结构，然后对标准视图进行切片显示。这个程序的加入可以减少操作人员之间的差异，因为最佳视图是基于数千个代表解剖变异谱的 DL 模型来选择的。有研究^[8] 显示，一个用来识别 8 个标准的三维超声心动图视图的 CNN，与临床医生标记的训练数据相比，准确率达到了 92%。这种图像采集的自动化可以帮助非心脏病医生在急性情况下使用超声心动图作为一线诊断工具，也有助于年轻心脏超声医师的培训。

对于心脏磁共振成像 (magnetic resonance imaging, MRI)，高质量的成像需要有经验的操作者细心地为患者定位和规划图像采集平面。有公司已经开发了基于 ML 的心脏解剖定位和采集平面自动规划软件，其与人工方法高度一致^[9-10]。还有研究者应用 RF^[11] 和 CNN^[12] 对成像伪影进行实时检测和消除。

2.1.2 图像分割 在超声心动图中，左心室一直是大多数 AI 分割研究的焦点。与专家相比，使用 RF 分类器的全自动 ML 算法在二维超声心动图上描绘左心室心内膜边界时表现出了良好的准确性^[13]。还有研究者^[14] 应用 500 例患者的二维超声图像标记数据集训练了一个 DL 模型，其在左心室心内膜和心外膜边界分割方面均优于最先进的非 DL 方法。

可能是因为近年来心脏 MRI 分割任务所需的开放数据集增加了，心脏 MRI 中基于 AI 的分割算法比其它任何心脏成像方式都要多。目前，大部分研究都集中在心腔分割，在异常心肌组织区域的分割方面有相对较少的研究，如左心室瘢痕和心房纤维化。描绘心室和心肌的边界是心脏 MRI 后处理的一个必需步骤，然而手工描绘非常耗时，而且存在描绘者偏差^[15]。研究^[16] 表明，AI 算法可以自动完成这项任务，同时有望提高准确性和可重复性。有研究者^[17] 基于一个来自英国生物样本库的 4 875 名受试者和 93 500 张图像的数据集，应用全卷积神经网络 (fully convolutional neural network, FCN) 的模型对所有 4 个心腔进行了分割，其表现和临床专家一样好。另一个研究^[18] 证实，CNN 可以准确地分割左心室和描绘出与心脏病理相关的解剖形态变化。然而，目前的 DL 分割模型缺乏可靠性，常常不能与专家达成一致，或者会输出不符合解剖学的分割结果^[16]。

DL 在心脏 CT 中的首次应用是一种使用边缘空间学习的算法，该算法通过逐步学习较低维的边



缘空间中的分类器来建模，并自动从三维体积中分割出所有4个心脏等^[19]。后来，Gurpreet等^[20]将U-Net(一个专为医学图像分割设计的FCN)应用于心脏CT的分割中，获得更为良好的表现。

2.1.3 自动测量 AI已在二维和三维超声心动图的参数自动测量方面应用较多。早期的软件使用传统的ML，基于二维左心室容积自动快速准确计算出左心室射血分数^[21]。此后，ML和DL算法被用于量化其它各种参数，如左心室肥大^[22]、心肌运动特征^[23]和纵向应变^[24]。而目前的腔室定量指南推荐使用准确性和可重复性更好的三维超声心动图^[25]。但是，三维超声心动图需要专门的训练并费时，这限制了其在常规临床实践中的广泛应用。研究^[26-27]证实，基于三维超声心动图，ML技术可以提供整个心动周期内快速、可重复的左心室和左心房容积自动测量，其参考值与心脏MRI相当。对这些ML算法进一步改进后，目前已经能够测定左心室质量^[28]、右心室容积和射血分数^[29]。

DL也可以用来量化心脏MRI上的一些参数。自动检测心肌边界的左心室分割算法现在可以全自动测量左心室体积、射血分数和质量，结果与专家高度一致^[30-32]。有研究^[33-34]已经应用DL算法自动分割右心室心内膜，可以得到跟专家测量一样精确的右心室体积和射血分数。另外，基于CNN的算法能够在特征空间中将左心室瘢痕与正常心肌分离，并准确量化缺血^[35]和肥厚型^[36]心肌病患者的瘢痕体积。同样，有研究^[37-38]提出全自动测量慢性心房颤动患者左心房瘢痕程度的模型，有利于更好地筛选需要导管消融的患者和选择合适的消融策略。

冠状动脉(冠脉)狭窄的检测和量化可能是冠脉CT最重要的临床应用，目前的报告是基于临床医生的主观视觉评估。Kelm等^[39]使用ML算法自动识别、分级和分类钙化斑块和非钙化斑块引起的冠脉狭窄。通过中心线提取和管腔分割，在229个CT数据上训练其RF模型，可以准确地进行狭窄识别和管腔横截面积估计，平均每例处理时间为1.8 s。同样，Zreik等^[40]成功训练出一个CNN来准确检测冠脉斑块，确定其组成，并可将冠脉狭窄分为阻塞性和非阻塞性。

2.2 心电图

随着可穿戴设备的增加，ML在心电图异常的自动检测中可能非常有用。Ali等^[41]使用DL算法自动检测心电心律失常，应用的数据集是超过4 000份长期心电动态心电图记录，最终该方法判别的平均正确率为92.4%。Attia等^[42]研究表明，CNN也可以帮助从心电图中识别无症状左心室收

缩功能障碍患者。Galloway等^[43]研究基于心电图的ML来筛查慢性肾病患者的高钾血症，数据集是来自梅奥诊所等3个中心的449 380例患者的1 576 581份心电图，最终该方法的受试者工作特征曲线下面积(area under the receiver operating characteristic curve, AUC)为0.853~0.883，敏感性为88.9%~91.3%。心电图具有无创、便宜和可重复的特点，是临床最常用的检查之一，这些基于心电图的AI筛查模型的研究，有望增加心电图诊断多种疾病的准确性，同时拓宽心电图可诊断的病种范围。

2.3 心血管不良事件预测

利用多种临床数据训练AI模型来预测心血管不良事件的发生，可以帮助医生提前辨别出不同风险层的患者，为他们制定个体化诊疗计划，以及进行更有针对性的随访方案，进一步降低死亡率和不良事件的发生。Johnsson等^[44]应用人工神经网络(artificial neural network, ANN)建立院外心脏骤停后的预测模型，数据集来自36个中心的932例患者，采用54个临床变量作为输入变量，最终AUC为0.891，表现明显比逻辑回归模型好，即使是简化的ANN模型，即只将年龄、恢复自主循环时间和首次监测的心律情况作为输入变量，其AUC>0.852，同样显示出良好的性能，且更方便临床使用。

Motwani等^[45]使用10 030例冠心病患者的冠脉CT数据集进行ML模型训练，对预后进行预测。他们将44个CT衍生的参数，连同25个临床参数，应用于ML算法预测5年随访的结果。首先根据信息增益排名自动选择特征，然后使用LogitBoost算法构建模型，再进行十折交叉验证。训练得到的ML模型预测死亡的AUC为0.79，显著高于单独使用传统危险因素或CT参数建立的模型。van Rosendael等^[46]通过仅使用心脏CT衍生的影像学标记训练的ML模型预测8 844例冠心病患者的预后，最终证实其ML模型在预测不良事件方面(AUC为0.771)明显优于所有其它冠脉CT评分(AUC为0.69~0.70)。Johnson等^[47]研究了4种不同的ML模型的性能，使用64排心脏CT衍生的血管特征来预测6 892例患者中是否有后续死亡或心血管事件。结果表明，ML模型对主要心血管不良事件患者的鉴别能力同样优于所有传统冠脉CT评分。

心脏手术相关性急性肾损伤(CSA-AKI)方面，Lee等^[48]基于2 010例心脏手术患者的数据，用6种机器学习方法分别建立模型，输入的参数包括临床基线资料、术中麻醉和手术数据，最终，XGBoost模型的AUC最高，为0.78，明显高于传统逻辑回归分析的0.69，决策树、RF和SVM与后者性能相



当。Tseng 等^[49]做了类似的研究,数据量共计 671 例,最终得出集成 RF 和 XGBoost 的 ML 模型的 AUC 最高,为 0.839,比单独的 RF 模型高。另外,Li 等^[50]用贝叶斯网络做了相应的模型,数据量共计 5 533 例,用来预测 CSA-AKI 和严重 CSA-AKI,最终内部验证 AUC 分别为 0.755 和 0.845,外部验证 AUC 分别为 0.736 和 0.816,表现较为出色。

有 2 项研究^[51-52]基于 ML 的方法对术后死亡风险进行预测,证实 ML 模型效能表现比 EuroSCORE (European System for Cardiac Operative Risk Evaluation) 模型更好。Kwon 等^[53]将 25 776 例患者的超声心动图报告格式化后,输入 DL 模型训练,得到了预测住院死亡率的模型,DL 模型在内部验证、外部验证、冠心病分组和心力衰竭分组的 AUC 分别为 0.912、0.898、0.958 和 0.913,明显优于其它模型。Kilic 等^[54]基于 XGBoost 算法开发了一个预测心脏手术死亡的模型,数据量共计 11 190 例,与胸外科医师协会预测死亡风险模型 (the Society of Thoracic Surgeons predicted risk of mortality, STS-PROM) 相比,AUC 相近,但是模型的其它性能有适当的改善。Fernandes 等^[55]比较了 5 种算法在预测心脏手术死亡风险的效能,数据量共计 5 015

例,最终发现 XGBoost 算法效能最佳,AUC 为 0.88。Hernandez-Suarez 等^[56]训练和比较 4 种预测经导管主动脉瓣置换术 (TAVR) 术后住院死亡率的 ML 模型,数据量为 10 883 例,最终发现逻辑回归 ML 模型效能为最佳,AUC 为 0.92,其中,急性肾损伤是住院死亡最重要的预测因子(表 1)。

2.4 先天性心脏病相关预测

成人先天性心脏病方面,一项研究^[57]纳入 10 019 例成年先天性心脏病患者,收集他们的临床、人口和检查等数据,输入原始数据训练 DL 模型,用来预测诊断、疾病复杂性和心功能分级 (NYHA),准确率分别为 91.1%、97.0% 和 90.6%,同时预测 6 个月内是否会进行多学科讨论,准确率为 90.2%,而在药物处理方面的预测准确率为 89.1%~94.3%。

Diller 等^[58]利用 DL 对法洛四联症患者心脏 MRI 图像进行自动分割和测量,得到相应的参数用来预测中远期的死亡,发现自动测得的右心房平均面积和右心室纵向应变是预后的重要预测因子,如果右心房面积增大和右心室纵向应变下降,不良结局风险就会显著增加。

Ruiz 等^[59]利用 93 例单心室患儿临床数据训练贝叶斯模型,开发出一套心脏重症监护预警指数

表 1 心血管不良事件 AI 预测模型

文献	研究人群	例数	输入变量	算法	预测指标	最佳算法及其 AUC
Johnsson 2020 ^[44]	OHCA	932	入院前后资料	ANN	大脑功能分级	0.891
Motwani 2017 ^[45]	CHD	10 030	CCTA 特征+临床数据	LogitBoost	死亡	0.79
van Rosendael 2018 ^[46]	CHD	8 844	CCTA 特征	XGBoost	心梗和死亡	0.771
Johnson 2019 ^[47]	CHD	6 892	CCTA 特征	ML (4 种)	心梗和死亡	KNN, 0.77 (死亡) 0.85 (CHD 相关死亡) 0.85 (心梗或死亡)
Lee 2018 ^[48]	CS	2 010	围术期临床数据	ML (6 种)	CSA-AKI	XGBoost, 0.78
Tseng 2020 ^[49]	CS	671	围术期临床数据	ML (5 种)	CSA-AKI	RF+XGBoost, 0.839
Li 2020 ^[50]	CS	5 533	围术期临床数据	BNs	CSA-AKI 严重 CSA-AKI	0.755 0.845
Allyn 2017 ^[52]	CS	6 520	围术期临床数据	ML (5 种)	围术期死亡	组合 ML, 0.795
Kwon 2019 ^[53]	CS	25 776	心脏超声心动图报告	DL	围术期死亡	0.912 (内部验证) 0.898 (外部验证) 0.958 (CHD) 0.913 (心衰)
Kilic 2020 ^[54]	CS	11 190	围术期临床数据	XGBoost	围术期死亡	0.808
Fernandes 2021 ^[55]	CS	5 015	围术期临床数据	ML (5 种)	围术期死亡	XGBoost, 0.88
Hernandez-Suarez 2019 ^[56]	TAVR	10 883	围术期临床数据	ML (4 种)	院内死亡	LR, 0.92

AUC: 受试者工作特征曲线下面积; OHCA: 院外心脏骤停; ANN: 人工神经网络; CHD: 冠心病; CCTA: 冠脉计算机断层扫描成像; XGBoost: 极端梯度提升; ML: 机器学习; KNN: K-邻近算法; CS: 心脏手术; CSA-AKI: 心脏手术相关性急性肾损伤; BNs: 贝叶斯网络; RF: 随机森林; DL: 深度学习; TAVR: 经导管主动脉瓣置换术; LR: 逻辑回归; 心衰: 心力衰竭; 心梗: 心肌梗死

(C-WIN)模型，在危险事件发生前的1 h、2 h、4 h、6 h和8 h 5个层面进行预测，最终C-WIN模型在不同层面的AUC在0.73~0.88之间，而在危险事件发生前的1 h，AUC为0.88，敏感性为84%，特异度为81%，这样有利于医生对危重患者进行及时干预。

Chu等^[60]基于利用7种ML方法建立了先心病孕妇和其胎儿不良事件发生的风险模型，ML模型的准确率和AUC分别接近0.8和0.7，效果良好，有助于临床医生对患有先天性心脏病的孕妇进行精准的分层管理和诊疗。

2.5 高危人群心血管不良事件预测

Alaa等^[61]应用DL方法，利用英国生物样本库中的423 604名基线资料无心血管疾病的居民数据，开发了相应的心血管疾病风险预测模型，每例数据均有473个参考变量，其中包含常见的风险因素，即年龄、性别、吸烟情况、血压、糖尿病史、高血压和体重指数等。最终得出的模型AUC为0.774，比Framingham评分和Cox比例危险率模型显著高，证明该自动预测模型具有更好的效能，其中5年心血管病发生事件为4 801例，自动预测模型成功预测的例数比Framingham评分多368例。

Dimopoulos等^[62]进行了类似的研究，其研究数据来自希腊一项纳入2 020名成人的前瞻性研究。应用KNN、RF和决策树3种模型进行训练，评估10年心血管疾病发病率，最后与HellenicSCORE模型(即校准过的EuroSCORE模型)进行比较。最终结果显示，HellenicSCORE总体效能最好，RF模型效能与之接近，KNN算法表现最差。

Naushad等^[63]尝试开发一种冠脉疾病早期预测工具。他们所用的算法包括集成ML算法(EMLA)，多因素降维(MDR)和递归分区(RP)，数据库共有648例(364例患者和284名健康人)，输入变量包括5个人口统计学特征、3个常规特征和14个遗传特征，输出变量为冠脉疾病发生和冠脉狭窄。最终发现EMLA模型在疾病发生预测(89.3%)和狭窄预测(82.5%)方面优于其它模型，AUC为0.96，也明显优于其它两个模型。

3 小结与展望

本文综述的研究均展示出AI在心血管医学中的适用性和有效性，尤其是数据处理上，相比传统统计学，AI往往具有更好的预测性能。然而，心血管疾病相关的AI研究也存在一定的门槛，主要的门槛是算力、数据质量和算法适配。算力方面，由于芯片研发的进步、高性能运算设备的普及和云计算的兴起，高算力的获得不是太大的问题。数据质

量方面，在国外，诊疗流程电子化和数据标准化程度比国内高，所以回顾性的数据质量比较高，也比较容易获得，因此AI模型做起来相对简单，相比之下，为了获得质量更好的数据，我们还需要加强诊疗流程电子化和数据标准化程度。算法适配方面，目前国内的AI专家团队其实不少，同时也有不少创业公司，因此只要医生团队积极寻求合作，就能获得相应的技术支持。长远来说，AI距离临床全面应用，还有很长的路要走，中间需要面临的挑战包括但不限于：(1)“黑匣子”效应，AI模型对数据处理的过程和得出的规律很难用人能理解的方式表现出来，因此就像一个“黑匣子”，具有不可解释性和不确定性，医生和患者都很难接受；(2)伦理的矛盾，AI模型做出决策时做不到考虑人文伦理等因素，真正应用一定会面临伦理的矛盾；(3)各方利益的权衡，AI模型可能会消灭一部分医学中的重复性劳动，也可能会新增一些工作和岗位，新旧交替中各方可能存在利益的权衡需要解决；(4)诊疗方式革新带来的其它改变，包括医生工作模式的改变、数据的应用安全、AI相关项目收费成本核算与分配等。

综上所述，AI可以辅助医护人员更高效地工作，可以帮助医生做出更全面和精确的决策，同时可以预测患者的预后并提醒医生尽早干预，未来可能会消除现代临床实践中许多乏味的工作，让医生有更多的精力放在需要解读和研究的地方。相比其它专业，心血管疾病的诊疗更依赖于多种模态的临床数据，最佳的决策应该是基于所有可能有用的数据而得出的，因此未来的心血管医生必将使用AI模型和软件作为临床常规辅助工具。总之，基于大数据的AI在心血管医学的应用研究才刚起步，机遇与挑战并存，前景广阔。

利益冲突：无。

作者贡献：邱海龙负责论文设计与初稿撰写；郭惠明、姚泽阳、谢稳、徐小维、黄美萍、岑坚正负责论文审阅与部分内容修改；庄建负责论文设计、审阅与修改。

参考文献

- Sacco RL, Roth GA, Reddy KS, et al. The heart of 25 by 25: Achieving the goal of reducing global and regional premature deaths from cardiovascular diseases and stroke: A modeling study from the American Heart Association and World Heart Federation. *Circulation*, 2016, 133(23): e674-e690.
- Zhou M, Wang H, Zhu J, et al. Cause-specific mortality for 240 causes in China during 1990-2013: A systematic subnational analysis for the Global Burden of Disease Study 2013. *Lancet*, 2016, 387(10015): 251-272.

- 3 Goff DC, Lloyd-Jones DM, Bennett G, et al. 2013 ACC/AHA guideline on the assessment of cardiovascular risk: A report of the American College of Cardiology/American Heart Association Task Force on Practice Guidelines. *J Am Coll Cardiol*, 2014, 63(25 Pt B): 2935-2959.
- 4 Hippisley-Cox J, Coupland C, Vinogradova Y, et al. Predicting cardiovascular risk in England and Wales: Prospective derivation and validation of QRISK2. *BMJ*, 2008, 336(7659): 1475-1482.
- 5 D'Agostino RB, Vasan RS, Pencina MJ, et al. General cardiovascular risk profile for use in primary care: The Framingham Heart Study. *Circulation*, 2008, 117(6): 743-753.
- 6 Ridker PM, Buring JE, Rifai N, et al. Development and validation of improved algorithms for the assessment of global cardiovascular risk in women: The Reynolds Risk Score. *JAMA*, 2007, 297(6): 611-619.
- 7 Alsharqi M, Woodward WJ, Mumith JA, et al. Artificial intelligence and echocardiography. *Echo Res Pract*, 2018, 5(4): R115-R125.
- 8 Gao Xiaohong, Li Wei, Loomes Martin, et al. A fused deep learning architecture for viewpoint classification of echocardiography. *Inform Fusion*, 2016, 36: 103-113.
- 9 Blansit K, Retson T, Masutani E, et al. Deep learning-based prescription of cardiac MRI planes. *Radiol Artif Intell*, 2019, 1(6): e180069.
- 10 Carmel H, Devos D, Lu XG. Fully automatic planning of the long-axis views of the heart. *J Cardiovasc Magn Reson*, 2013, 15(Suppl 1): O54.
- 11 Lorch B, Vaillant G, Baumgartner C, et al. Automated detection of motion artefacts in MR imaging using decision forests. *J Med Eng*, 2017, 2017: 4501647.
- 12 Hauptmann A, Arridge S, Lucka F, et al. Real-time cardiovascular MR with spatio-temporal artifact suppression using deep learning—proof of concept in congenital heart disease. *Magn Reson Med*, 2019, 81(2): 1143-1156.
- 13 Leclerc S, Grenier T, Espinosa F, et al. A fully automatic and multi-structural segmentation of the left ventricle and the myocardium on highly heterogeneous 2D echocardiographic data. Washington: 2017 IEEE International Ultrasonics Symposium (IUS).
- 14 Leclerc S, Smistad E, Pedrosa J, et al. Deep learning for segmentation using an open large-scale dataset in 2D echocardiography. *IEEE Trans Med Imaging*, 2019, 38(9): 2198-2210.
- 15 Suinesiaputra A, Bluemke DA, Cowan BR, et al. Quantification of LV function and mass by cardiovascular magnetic resonance: Multi-center variability and consensus contours. *J Cardiovasc Magn Reson*, 2015, 17(1): 63.
- 16 Bernard O, Lalande A, Zotti C, et al. Deep learning techniques for automatic MRI cardiac multi-structures segmentation and diagnosis: Is the problem solved? *IEEE Trans Med Imaging*, 2018, 37(11): 2514-2525.
- 17 Bai W, Sinclair M, Tarroni G, et al. Automated cardiovascular magnetic resonance image analysis with fully convolutional networks. *J Cardiovasc Magn Reson*, 2018, 20(1): 65.
- 18 Oktay O, Ferrante E, Kamnitsas K, et al. Anatomically Constrained Neural Networks (ACNNs): Application to cardiac image enhancement and segmentation. *IEEE Trans Med Imaging*, 2018, 37(2): 384-395.
- 19 Zheng Y, Barbu A, Georgescu B, et al. Four-chamber heart modeling and automatic segmentation for 3-D cardiac CT volumes using marginal space learning and steerable features. *IEEE Trans Med Imaging*, 2008, 27(11): 1668-1681.
- 20 Gurpreet S, Subhi A, Gabriel M, et al. Deep learning based automatic segmentation of cardiac computed tomography. *J Am Coll Cardiol*, 2019, 73(Suppl 9): 1643.
- 21 Cannesson M, Tanabe M, Suffoletto MS, et al. A novel two-dimensional echocardiographic image analysis system using artificial intelligence-learned pattern recognition for rapid automated ejection fraction. *J Am Coll Cardiol*, 2007, 49(2): 217-226.
- 22 Madani A, Ong JR, Tibrewal A, et al. Deep echocardiography: Data-efficient supervised and semi-supervised deep learning towards automated diagnosis of cardiac disease. *NPJ Digit Med*, 2018, 1: 59.
- 23 Sanchez-Martinez S, Duchateau N, Erdei T, et al. Characterization of myocardial motion patterns by unsupervised multiple kernel learning. *Med Image Anal*, 2017, 35: 70-82.
- 24 Knackstedt C, Bekkers SC, Schummers G, et al. Fully automated versus standard tracking of left ventricular ejection fraction and longitudinal strain: The FAST-EFs multicenter study. *J Am Coll Cardiol*, 2015, 66(13): 1456-1466.
- 25 Lang RM, Badano LP, Mor-Avi V, et al. Recommendations for cardiac chamber quantification by echocardiography in adults: An update from the American Society of Echocardiography and the European Association of Cardiovascular Imaging. *J Am Soc Echocardiogr*, 2015, 28(1): 1-39.
- 26 Narang A, Mor-Avi V, Prado A, et al. Machine learning based automated dynamic quantification of left heart chamber volumes. *Eur Heart J Cardiovasc Imaging*, 2019, 20(5): 541-549.
- 27 Tsang W, Salgo IS, Medvedofsky D, et al. Transthoracic 3D Echocardiographic left heart chamber quantification using an automated adaptive analytics algorithm. *JACC Cardiovasc Imaging*, 2016, 9(7): 769-782.
- 28 Volpatto V, Mor-Avi V, Narang A, et al. Automated, machine learning-based, 3D echocardiographic quantification of left ventricular mass. *Echocardiography*, 2019, 36(2): 312-319.
- 29 Genovese D, Rashedi N, Weinert L, et al. Machine learning-based three-dimensional echocardiographic quantification of right ventricular size and function: Validation against cardiac magnetic resonance. *J Am Soc Echocardiogr*, 2019, 32(8): 969-977.
- 30 Suinesiaputra A, Sanghvi MM, Aung N, et al. Fully-automated left ventricular mass and volume MRI analysis in the UK Biobank population cohort: Evaluation of initial results. *Int J Cardiovasc Imaging*, 2018, 34(2): 281-291.
- 31 Ngo TA, Lu Z, Carneiro G. Combining deep learning and level set for the automated segmentation of the left ventricle of the heart from cardiac cine magnetic resonance. *Med Image Anal*, 2017, 35: 159-171.
- 32 Marino M, Veronesi F, Corsi C. Fully automated assessment of left ventricular volumes and mass from cardiac magnetic resonance images. *Annu Int Conf IEEE Eng Med Biol Soc*, 2014, 2014: 1079-1082.
- 33 Avendi MR, Kheradvar A, Jafarkhani H. Automatic segmentation of the right ventricle from cardiac MRI using a learning-based approach. *Magn Reson Med*, 2017, 78(6): 2439-2448.
- 34 Petitjean C, Zuluaga MA, Bai W, et al. Right ventricle segmentation from cardiac MRI: A collation study. *Med Image Anal*, 2015, 19(1): 187-202.
- 35 Zabihollahy F, White JA, Ukwatta E. Convolutional neural network-based approach for segmentation of left ventricle myocardial scar from 3D late gadolinium enhancement MR



- images. *Med Phys*, 2019, 46(4): 1740-1751.
- 36 Fahmy AS, Neisius U, Chan RH, et al. Three-dimensional deep convolutional neural networks for automated myocardial scar quantification in hypertrophic cardiomyopathy: A multicenter multivendor study. *Radiology*, 2020, 294(1): 52-60.
- 37 Yang G, Zhuang X, Khan H, et al. Fully automatic segmentation and objective assessment of atrial scars for long-standing persistent atrial fibrillation patients using late gadolinium-enhanced MRI. *Med Phys*, 2018, 45(4): 1562-1576.
- 38 Tao Q, Ipek EG, Shahzad R, et al. Fully automatic segmentation of left atrium and pulmonary veins in late gadolinium-enhanced MRI: Towards objective atrial scar assessment. *J Magn Reson Imaging*, 2016, 44(2): 346-354.
- 39 Kelm BM, Mittal S, Zheng Y, et al. Detection, grading and classification of coronary stenoses in computed tomography angiography. *Med Image Comput Comput Assist Interv*, 2011, 14(Pt 3): 25-32.
- 40 Zreik M, van Hamersvelt RW, Wolterink JM, et al. A recurrent CNN for automatic detection and classification of coronary artery plaque and stenosis in coronary CT angiography. *IEEE Trans Med Imaging*, 2019, 38(7): 1588-1598.
- 41 Ali I, Selen O. Cardiac arrhythmia detection using deep learning. *Proc Comp Sci*, 2017: 120268-275.
- 42 Attia ZI, Kapa S, Lopez-Jimenez F, et al. Screening for cardiac contractile dysfunction using an artificial intelligence-enabled electrocardiogram. *Nat Med*, 2019, 25(1): 70-74.
- 43 Galloway CD, Valys AV, Shreibati JB, et al. Development and validation of a deep-learning model to screen for hyperkalemia from the electrocardiogram. *JAMA Cardiol*, 2019, 4(5): 428-436.
- 44 Johnsson J, Björnsson O, Andersson P, et al. Artificial neural networks improve early outcome prediction and risk classification in out-of-hospital cardiac arrest patients admitted to intensive care. *Crit Care*, 2020, 24(1): 474.
- 45 Motwani M, Dey D, Berman DS, et al. Machine learning for prediction of all-cause mortality in patients with suspected coronary artery disease: A 5-year multicentre prospective registry analysis. *Eur Heart J*, 2017, 38(7): 500-507.
- 46 van Rosendael AR, Maliakal G, Kolli KK, et al. Maximization of the usage of coronary CTA derived plaque information using a machine learning based algorithm to improve risk stratification; Insights from the CONFIRM registry. *J Cardiovasc Comput Tomogr*, 2018, 12(3): 204-209.
- 47 Johnson KM, Johnson HE, Zhao Y, et al. Scoring of coronary artery disease characteristics on coronary CT angiograms by using machine learning. *Radiology*, 2019, 292(2): 354-362.
- 48 Lee HC, Yoon HK, Nam K, et al. Derivation and validation of machine learning approaches to predict acute kidney injury after cardiac surgery. *J Clin Med*, 2018, 7(10): 322.
- 49 Tseng PY, Chen YT, Wang CH, et al. Prediction of the development of acute kidney injury following cardiac surgery by machine learning. *Crit Care*, 2020, 24(1): 478.
- 50 Li Y, Xu J, Wang Y, et al. A novel machine learning algorithm, Bayesian networks model, to predict the high-risk patients with cardiac surgery-associated acute kidney injury. *Clin Cardiol*, 2020, 43(7): 752-761.
- 51 Kartal E, Balaban ME. Machine learning techniques in cardiac risk assessment. *Turk Gogus Kalp Damar Cerrahisi Derg*, 2018, 26(3): 394-401.
- 52 Allyn J, Allou N, Augustin P, et al. A comparison of a machine learning model with EuroSCORE II in predicting mortality after elective cardiac surgery: A Decision Curve Analysis. *PLoS One*, 2017, 12(1): e0169772.
- 53 Kwon JM, Kim KH, Jeon KH, et al. Deep learning for predicting in-hospital mortality among heart disease patients based on echocardiography. *Echocardiography*, 2019, 36(2): 213-218.
- 54 Kilic A, Goyal A, Miller JK, et al. Predictive utility of a machine learning algorithm in estimating mortality risk in cardiac surgery. *Ann Thorac Surg*, 2020, 109(6): 1811-1819.
- 55 Fernandes MPB, Armengol de la Hoz M, Rangasamy V, et al. Machine learning models with preoperative risk factors and intraoperative hypotension parameters predict mortality after cardiac surgery. *J Cardiothorac Vasc Anesth*, 2021, 35(3): 857-865.
- 56 Hernandez-Suarez DF, Kim Y, Villablanca P, et al. Machine learning prediction models for in-hospital mortality after transcatheter aortic valve replacement. *JACC Cardiovasc Interv*, 2019, 12(14): 1328-1338.
- 57 Diller GP, Kempny A, Babu-Narayan SV, et al. Machine learning algorithms estimating prognosis and guiding therapy in adult congenital heart disease: Data from a single tertiary centre including 10 019 patients. *Eur Heart J*, 2019, 40(13): 1069-1077.
- 58 Diller GP, Orwat S, Vahle J, et al. Prediction of prognosis in patients with tetralogy of Fallot based on deep learning imaging analysis. *Heart*, 2020, 106(13): 1007-1014.
- 59 Ruiz VM, Saenz L, Lopez-Magallon A, et al. Early prediction of critical events for infants with single-ventricle physiology in critical care using routinely collected data. *J Thorac Cardiovasc Surg*, 2019, 158(1): 234-243.
- 60 Chu R, Chen W, Song G, et al. Predicting the risk of adverse events in pregnant women with congenital heart disease. *J Am Heart Assoc*, 2020, 9(14): e016371.
- 61 Alaa AM, Bolton T, Di Angelantonio E, et al. Cardiovascular disease risk prediction using automated machine learning: A prospective study of 423, 604 UK Biobank participants. *PLoS One*, 2019, 14(5): e0213653.
- 62 Dimopoulos AC, Nikolaidou M, Caballero FF, et al. Machine learning methodologies versus cardiovascular risk scores, in predicting disease risk. *BMC Med Res Methodol*, 2018, 18(1): 179.
- 63 Naushad SM, Hussain T, Indumathi B, et al. Machine learning algorithm-based risk prediction model of coronary artery disease. *Mol Biol Rep*, 2018, 45(5): 901-910.

收稿日期：2021-03-24 修回日期：2021-05-31

本文编辑：董敏